Relatório — Ataque de evasão contra o classificador Moto × Bicicleta

IA para Cibersegurança — Aula 10 · Ataques adversariais em imagens (FGSM e PGD)

Equipe: Arthur Leandro · Gabriel Peixoto · Pedro Pimentel

Cenário. Classificador de imagens treinado no Teachable Machine (Aula 2), baseado em MobileNetV2, com **duas classes: Bicicleta e Moto**. Entrada 224×224 normalizada em [-1, 1]. Os ataques são de **evasão, white-box** (temos acesso ao gradiente do modelo) e **sem alvo**: o objetivo é só fazer o modelo errar. O **ε** é medido na mesma escala [-1, 1]; por exemplo, ε = 0,01 corresponde a ~1,3 nível de cor em 255.

Todos os números abaixo vêm das saídas do notebook da aula (`notebook7.ipynb`), executado no Colab.

1. Acurácia do modelo (baseline)

Medida	Valor
Acurácia no conjunto de teste, sem ataque	**79%** (11 de 14 imagens)
Imagem atacada (`exemplo.png`, classe Moto)	**Moto, confiança 1,000** (Bicicleta: 0,000)

O modelo vai bem nas condições normais e está **totalmente confiante** na imagem escolhida. Isso torna o resultado do ataque mais significativo: não estamos explorando uma imagem em que o modelo já estava em dúvida.

> Observação: o conjunto de teste é pequeno (14 imagens), então cada imagem vale ~7 p.p. de acurácia.

2. Exemplos adversariais: antes e depois

Original (baseline): Moto, confiança 1,00



FGSM, ε = 0,01 (epsilon crítico): Moto 1,00 → **Bicicleta 0,68**. Nenhuma diferença visível; a perturbação só aparece quando amplificada (painel da direita).



PGD, ε = 0,03, 20 passos: Moto 1,00 → **Bicicleta 1,00**. Continua imperceptível.



FGSM com alvo (Bicicleta), ε = 0,10: Moto 1,00 → **Bicicleta 1,00**. Aqui a perturbação já **é visível**: a imagem fica granulada, principalmente no muro e no chão.



3. Taxa de sucesso do ataque (FGSM e PGD)

Na imagem atacada: os dois ataques tiveram **100% de sucesso**. FGSM virou a classe com ε = 0,01; PGD virou com ε = 0,03, levando a confiança no erro a 1,00.

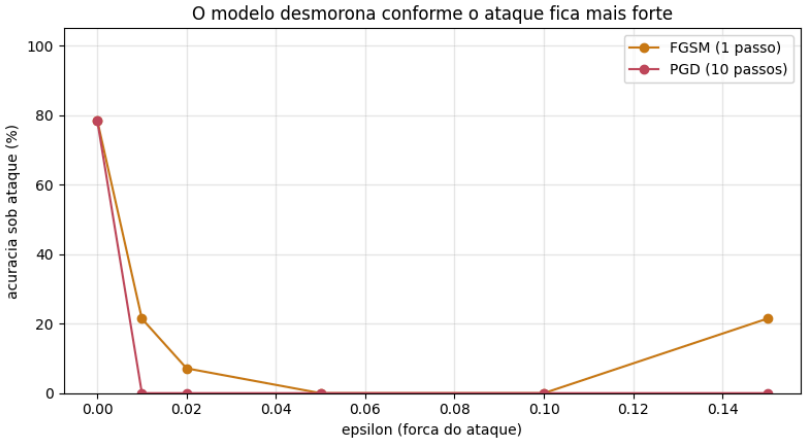
No conjunto de teste (14 imagens):

ε	Acurácia FGSM	Acurácia PGD (10 passos)	Taxa de sucesso FGSM*	Taxa de sucesso PGD*
0	79% (11/14)	79% (11/14)	—	—
0,01	21% (3/14)	**0%**	73% (8/11)	**100%**
0,02	7% (1/14)	0%	91% (10/11)	100%
0,05	**0%**	0%	**100%**	100%
0,10	0%	0%	100%	100%
0,15	21% (3/14)	0%	~73%	100%

** Taxa de sucesso = fração das 11 imagens que o modelo acertava sem ataque e passou a errar (≈ 1 − acurácia sob ataque ÷ acurácia sem ataque). Considera que as 3 imagens que o modelo já errava continuam erradas sob ataque.*

Leitura: o PGD atinge **100% de sucesso já no menor ε testado**. O FGSM precisa de ε = 0,05 (5× mais) para chegar lá.

4. Queda de acurácia: curva de robustez



	FGSM	PGD
Acurácia sem ataque	79%	79%
Acurácia mínima sob ataque	0% (a partir de ε = 0,05)	0% (a partir de ε = 0,01)
Queda máxima	**79 p.p.**	**79 p.p.**

Os dois ataques levam o modelo a **zero**, mas o PGD chega lá com uma perturbação 5× menor.

A curva do FGSM **não é monotônica**: em ε = 0,15 a acurácia sobe de volta para 21%. Isso **não** significa que o modelo fica mais robusto com ataques mais fortes, porque o PGD com o mesmo ε continua em 0%. É uma limitação do FGSM: ele dá um único salto na direção do gradiente calculado no ponto de partida e, com ε grande, essa aproximação linear deixa de valer e o salto “passa do ponto”.

5. Tabela de métricas: o tripé (imperceptibilidade, efetividade, custo)

Medida na imagem atacada (Moto, confiança original 1,000):

Ataque	L∞ (= ε)	L2	L0 (% alterado)	Virou?	Confiança depois (classe prevista)	Custo (passos)	Visível a olho nu?
FGSM, ε crítico	0,01	3,88	100%	**Sim**	0,681 (Bicicleta)	1	Não
FGSM, ε = 0,03	0,03	11,63	100%	**Sim**	0,988 (Bicicleta)	1	Não
PGD, ε = 0,03	0,03	**8,14**	**87,4%**	**Sim**	**1,000** (Bicicleta)	20	Não
FGSM com alvo, ε = 0,10	0,10	38,49	100%	**Sim**	0,998 (Bicicleta)	1	**Sim** (granulado)

Leitura do tripé:

- **Imperceptibilidade:** com o mesmo teto (L∞ = 0,03), o PGD gasta ~30% menos energia (L2 8,14 × 11,63) e mexe em menos valores. O FGSM no ε crítico é o mais discreto de todos (L2 = 3,88). Só o ataque com ε = 0,10 ficou perceptível.
- **Efetividade:** todos viraram a classe. O FGSM no limite vira "raspando" (0,68), enquanto o PGD leva o modelo a errar com **certeza total** (1,00).
- **Custo:** FGSM = 1 gradiente; PGD = 20 gradientes (20×). Para um modelo pequeno como este, os dois custam segundos.

6. Discussão: o que isso revela sobre a robustez do modelo

- **O modelo é preciso, mas não é robusto.** Ele acerta 79% das imagens limpas e tem 100% de confiança na moto atacada, mas uma mudança de ~1 nível de cor por pixel, invisível para nós, basta para trocar a resposta. Com PGD, a acurácia vai de 79% a **0%** já no menor ε testado.
- **Confiança alta não é sinal de segurança.** O modelo afirma "Bicicleta, 1,00" para uma foto que qualquer pessoa reconhece como moto. Um sistema que confie apenas no limiar de confiança seria enganado sem nenhum alerta.
- **O modelo não aprendeu o que nós entendemos por "moto".** Ele se apoia em padrões de pixel frágeis. Como a entrada tem ~150 mil valores (224×224×3), pequenas mudanças coordenadas em todos eles se somam e deslocam a saída. Treinar com poucas imagens no Teachable Machine (transfer learning sem nenhuma preocupação com robustez) agrava isso.
- **A avaliação precisa usar o ataque mais forte.** Se medíssemos só com FGSM, veríamos "21% de acurácia em ε = 0,15" e poderíamos concluir algo errado. O PGD mostra o pior caso real: **robustez zero** em toda a faixa testada.
- **Limitações do experimento:** 14 imagens de teste; ataque digital e white-box (perturbação aplicada direto no tensor já redimensionado, com acesso aos gradientes); métricas do tripé medidas em uma única imagem; PGD sem início aleatório nem reinícios. Num cenário black-box ou físico o ataque seria mais difícil, mas a fragilidade de fundo é a mesma.

Conclusão: o modelo é **altamente vulnerável a ataques de evasão**. O próximo passo é aplicar **treino adversarial com PGD** e refazer esta mesma curva acurácia × ε para medir quanto a defesa recupera.